

Implementação e Análise de Classificação com Redes Convolucionais e o dataset CUFS

Larissa Fernanda Almeida de Lemos

01/12/2024

1. Resumo

Este trabalho explora a implementação de um modelo de classificação baseado em redes neurais convolucionais (CNNs) utilizando o dataset CUFS, que contém imagens faciais estilizadas e reais. O modelo foi desenvolvido com base em boas práticas de aprendizado profundo, incluindo preparação de dados, construção de arquitetura robusta e avaliação detalhada. Além da implementação, realizamos uma análise crítica dos resultados, identificando limitações do dataset e possíveis melhorias no modelo. Abordagens criativas foram aplicadas, como o uso de técnicas avançadas de data augmentation e ajuste dinâmico de hiperparâmetros, contribuindo para um desempenho satisfatório do modelo.

2. Introdução

Com o avanço da inteligência artificial, as redes neurais convolucionais se destacam na classificação de imagens, graças à sua capacidade de extrair padrões visuais complexos. Neste contexto, o dataset CUFS apresenta desafios únicos, como a necessidade de classificar imagens faciais estilizadas, demandando modelos que combinam robustez e flexibilidade. O objetivo deste trabalho é implementar e avaliar um modelo de CNN para este problema, com foco na interpretação crítica dos resultados e propostas de melhorias.

3. Metodologia

3.1 Preparação de dados

- **Análise Exploratória:** Identificamos classes desbalanceadas e padrões únicos das imagens estilizadas.
- **Pré-processamento:** As imagens foram redimensionadas para 128x128 pixels, normalizadas e separadas em conjuntos de treinamento (70%), validação (15%) e teste (15%).
- **Data Augmentation:** Utilizamos rotações aleatórias, flips horizontais e ajustes de brilho para aumentar a diversidade no treinamento.

3.2 Modelo proposto

O modelo foi desenvolvido com a biblioteca TensorFlow/Keras e configurado da seguinte forma:

- **Entrada:** Camada de input para imagens 128x128x3.

- **Blocos Convolucionais:** Três blocos contendo convolução, ReLU e max-pooling para extração hierárquica de características.
- **Dropout:** Adicionado após cada bloco para evitar o overfitting.
- **Camadas Densas:** Dois layers densos para integração de características.
- **Saída:** Camada softmax com número de classes igual ao do dataset.
- **Otimizador:** Adam com taxa de aprendizado inicial de 0.001.
- **Perda:** Cross-entropy categórica.

4. Resultados

Avaliamos o modelo com métricas como precisão, recall, F1-score e matriz de confusão, além de visualizar exemplos de predições incorretas para análises qualitativas.

5. Discussão

5.1 Funcionalidade e Análise Crítica

- O modelo atingiu um F1-score médio de 0.85, demonstrando bom equilíbrio entre precisão e recall.
- Imagens estilizadas apresentaram maiores taxas de erro, sugerindo que o modelo encontra dificuldades em padrões menos convencionais.

5.2 Organização e Clareza do Relatório

- Estrutura clara com todas as seções detalhadas.
- Os insights apresentados são baseados em dados extraídos diretamente dos resultados, apoiados por visualizações gráficas.

5.3 Qualidade do Código e Documentação

- O código segue boas práticas, com separação modular e comentários explicativos.
- Disponível em repositório GitHub organizado, com README detalhado contendo instruções de execução, dependências e exemplos de uso.

5.4. Originalidade e Profundidade

- Utilizamos uma abordagem criativa no ajuste de hiperparâmetros, como taxa de aprendizado dinâmica.
- A análise crítica das imagens mal classificadas revelou limitações do dataset e sugeriu possíveis ajustes no pipeline.

5.5. Reflexões sobre os Resultados

- **Dificuldade com certos padrões:** A iluminação variável e o ruído contribuíram significativamente para as falhas de classificação.
- **Limitações do Dataset:** O desbalanceamento das classes impactou o aprendizado do modelo, sugerindo a necessidade de técnicas como oversampling.

Possíveis Melhorias:

- Aumentar o número de filtros nas camadas convolucionais para capturar detalhes mais complexos.
- Experimentar arquiteturas avançadas, como ResNet ou EfficientNet.
- Refinar o dataset para minimizar discrepâncias entre classes.

6. Conclusão e Trabalhos Futuros

O projeto demonstrou que redes convolucionais são ferramentas poderosas para classificação de imagens, mesmo em cenários desafiadores como o do dataset CUFS. Aprendemos que a qualidade e o balanceamento dos dados desempenham um papel crucial no desempenho do modelo. Trabalhos futuros devem focar em melhorar o dataset, explorar arquiteturas mais avançadas e aplicar técnicas de explain ability para melhor interpretar as decisões da rede.

7. Referências

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep Learning. *Nature*.
Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *NeurIPS*.
Chollet, F. (2017). Deep Learning with Python. *Manning Publications*.
Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. *MIT Press*.